

Partie 04 — Atelier

Mener une petite analyse de données

Oskar Laverny

Table des matières

Objectif	1
1. Importer et contrôler les données	1
2. Préparer un tableau d'analyse	1
3. Produire des résumés utiles	2
4. Répondre par des graphiques	2
Présentation attendue	2
5. Construire un graphique de synthèse	2
Travail demandé	2
6. Conclure	3
Prolongement facultatif	3
À remettre à la fin de l'atelier	3

Durée indicative : 75 à 90 minutes. Travaillez à votre rythme. Commencez par le parcours principal ; le prolongement est facultatif.

Objectif

Vous allez mener une petite analyse complète du fichier `patients.csv` : importer les données, les préparer, produire des résumés, choisir des représentations graphiques et formuler une conclusion descriptive.

Créez un script nommé `atelier_visualisation.R`. Il doit pouvoir être exécuté intégralement depuis une session R propre.

1. Importer et contrôler les données

1. Chargez `dplyr` et `ggplot2`.
2. Importez `data/patients.csv` dans un objet nommé `patients`.
3. Affichez les dimensions, les noms des colonnes et les six premières lignes.
4. Examinez la structure et le résumé des données.
5. Repérez les variables contenant des valeurs manquantes.

Ajoutez dans votre script un court commentaire décrivant le nombre d'observations, le nombre de variables et les valeurs manquantes repérées.

2. Préparer un tableau d'analyse

Créez un objet `patients_analyse` qui :

1. conserve `age`, `sexe`, `groupe`, `taille_cm`, `poids_kg`, `tas`, `traitement` et `score` ;

2. retire les lignes pour lesquelles `poids_kg`, `tas` ou `score` est manquant ;
3. crée `taille_m` en convertissant la taille en mètres ;
4. crée `imc` avec la formule $poids_kg / taille_m^2$;
5. crée trois classes d'âge : `< 40`, `40-64` et `65+` ;
6. trie les observations de l'IMC le plus élevé au plus faible.

Affichez les dix premières lignes de ce nouveau tableau et vérifiez les effectifs des classes d'âge.

3. Produire des résumés utiles

Construisez deux tableaux :

1. par `sexe`, calculez le nombre d'observations, l'âge moyen, la TAS moyenne et le score moyen ;
2. par `traitement`, calculez le nombre d'observations, l'IMC moyen et le score moyen.

Donnez des noms explicites aux colonnes produites. En deux ou trois lignes de commentaire, relevez les principales différences descriptives entre les groupes.

4. Répondre par des graphiques

Réalisez les trois graphiques suivants avec `ggplot2` :

1. un histogramme montrant la distribution de l'âge ;
2. des boxplots comparant le score selon le traitement ;
3. un nuage de points représentant la TAS en fonction de l'âge, avec une couleur selon le sexe, une facette par traitement et une droite de tendance linéaire sans intervalle de confiance.

Présentation attendue

Chaque graphique doit comporter :

- un titre qui indique clairement la question étudiée ;
- des axes nommés en français ;
- une légende explicite lorsque nécessaire ;
- un thème lisible.

5. Construire un graphique de synthèse

Choisissez **une** des questions suivantes :

- comment l'IMC varie-t-il selon le groupe et le sexe ?
- comment le score varie-t-il avec l'âge selon le traitement ?
- la relation entre l'âge et la TAS semble-t-elle différente selon le groupe ?

Travail demandé

Construisez un graphique qui permette de répondre à la question choisie. Vous êtes libre d'utiliser une couleur, des facettes ou une droite de tendance si cela améliore réellement la lecture.

Enregistrez ce graphique dans `resultats/graphique_synthese.png` avec `ggsave()`.

6. Conclure

Sous forme de commentaires à la fin du script, écrivez quatre à six lignes répondant aux questions suivantes :

1. quelle question avez-vous choisie ?
2. qu'observez-vous sur le graphique ?
3. quelles variables avez-vous utilisées pour parvenir à cette conclusion ?
4. pourquoi cette observation descriptive ne suffit-elle pas à établir une relation causale ?

Prolongement facultatif

Si vous terminez en avance :

1. construisez un diagramme en barres présentant la proportion de fumeurs selon le sexe ;
2. utilisez des facettes pour comparer cette proportion entre les groupes **A** et **B** ;
3. choisissez des labels et des couleurs qui rendent le graphique compréhensible sans lire le code ;
4. enregistrez-le dans `resultats/fumeurs.png`.

À remettre à la fin de l'atelier

Votre dossier doit contenir :

- le script `atelier_visualisation.R` ;
- le fichier `resultats/graphique_synthese.png` ;
- éventuellement `resultats/fumeurs.png` si vous avez réalisé le prolongement.

Avant de terminer, relancez votre script depuis le début afin de vérifier qu'il fonctionne sans dépendre d'objets créés manuellement dans le terminal.