

Partie 04 — Visualiser des données

INF-STAR — Programmation statistique avec R

Oskar Laverny

September 28, 2026

Aix-Marseille Université

Objectifs

À la fin de cette partie

Vous saurez :

- choisir un graphique adapté à une question simple ;
- produire rapidement un graphique en base R ;
- construire un graphique avec `ggplot2` ;
- utiliser couleur, facettes et labels sans surcharger la figure ;
- exporter un graphique.

Avant de tracer



Un graphique répond à une question

Avant de choisir une fonction, identifiez :

- la variable à expliquer ou décrire ;
- son type : numérique ou catégoriel ;
- l'éventuel groupe de comparaison ;
- le message que le lecteur doit pouvoir voir.

Le graphique n'est pas une décoration : c'est un outil d'analyse et de communication.

Une variable numérique

Questions fréquentes :

- quelle est la distribution ?
- y a-t-il des valeurs extrêmes ?
- où se situe le centre ?

Graphiques utiles : histogramme, densité, boxplot.

Deux variables numériques

Question : les deux variables semblent-elles associées ?

Graphique naturel : nuage de points.

```
plot(patients$age, patients$tas)
```

Base R : diagnostic rapide



Quelques fonctions à connaître

```
hist(patients$age)
boxplot(patients$tas)
plot(patients$age, patients$tas)
barplot(table(patients$traitement))
```

Ces fonctions sont pratiques pour une exploration rapide.

Nous consacrerons davantage de temps à **ggplot2** pour les figures construites et reproductibles.

Un minimum de personnalisation

```
hist(  
  patients$age,  
  main = "Distribution de l'âge",  
  xlab = "Âge (ans)"  
)
```

L'objectif est la lisibilité, pas la mémorisation de dizaines de paramètres graphiques.

La logique de `ggplot2`

```
library(ggplot2)

ggplot(patients, aes(x = age, y = tas)) +
  geom_point()
```

- `ggplot()` : les données ;
- `aes()` : quelles variables jouent quels rôles ;
- `geom_*()` : comment les représenter.

```
ggplot(patients, aes(x = age)) +  
  geom_histogram(binwidth = 5)
```

Le choix de `binwidth` influence la lecture de la distribution : essayez plusieurs valeurs raisonnables.

Boxplot par groupe

```
ggplot(patients, aes(x = sexe, y = tas)) +  
  geom_boxplot()
```

Un boxplot résume une distribution et facilite la comparaison entre groupes.

Nuage de points

```
ggplot(patients, aes(x = age, y = tas)) +  
  geom_point()
```

Avec transparence :

```
ggplot(patients, aes(age, tas)) +  
  geom_point(alpha = 0.6)
```

Couleur : variable ou constante ?

Variable :

```
ggplot(patients, aes(age, tas, color = sexe)) +  
  geom_point()
```

Constante :

```
ggplot(patients, aes(age, tas)) +  
  geom_point(color = "steelblue")
```

Dans `aes()`, la couleur dépend des données ; hors de `aes()`, elle est fixe.

Ajouter une tendance

```
ggplot(patients, aes(age, tas)) +  
  geom_point(alpha = 0.5) +  
  geom_smooth(method = "lm", se = FALSE)
```

Une droite de tendance aide à voir une association ; elle ne prouve pas une relation causale.

```
ggplot(patients, aes(age, tas)) +  
  geom_point() +  
  facet_wrap(~ traitement)
```

Les facettes permettent de comparer des sous-groupes avec les mêmes axes et la même structure graphique.

```
ggplot(patients, aes(age, tas)) +  
  geom_point() +  
  labs(  
    title = "Tension artérielle et âge",  
    x = "Âge (ans)",  
    y = "TAS"  
  )
```

Un axe doit être compréhensible sans lire le code.

```
ggplot(patients, aes(age, tas)) +  
  geom_point() +  
  theme_minimal()
```

Choisissez un thème simple et gardez-le cohérent entre les figures d'un même rapport.

Graphiques de données catégorielles

```
ggplot(patients, aes(x = traitement)) +  
  geom_bar()
```

`geom_bar()` compte les observations de chaque catégorie.

Proportions

On peut d'abord calculer les proportions avec `dplyr`, puis les représenter :

```
prop <- patients |>
  dplyr::count(traitement) |>
  dplyr::mutate(p = n / sum(n))
```

Puis :

```
ggplot(prop, aes(traitement, p)) +
  geom_col()
```

Exporter



```
p <- ggplot(patients, aes(age, tas)) +  
  geom_point()  
  
ggsave(  
  filename = "resultats/age_tas.png",  
  plot = p,  
  width = 7,  
  height = 5  
)
```

Le même code produit la même figure : c'est préférable à une exportation manuelle par clics.

Quelques règles pratiques

- choisissez des axes et unités explicites ;
- évitez trop de couleurs ou de symboles ;
- utilisez une légende seulement si elle apporte une information ;
- ne tronquez pas un axe pour exagérer une différence ;
- ne mettez pas 12 variables dans une seule figure.

Quel graphique choisir ?

Question	Graphique de départ
distribution d'une variable numérique	histogramme / boxplot
association entre deux numériques	nuage de points
comparer une numérique entre groupes	boxplot
compter des catégories	barres
même relation dans plusieurs groupes	facettes

Commencez simple, puis enrichissez uniquement si cela aide la lecture.

À retenir



Une structure que l'on réutilise

```
ggplot(donnees, aes(x = ..., y = ...)) +  
  geom_...() +  
  labs(...) +  
  theme_minimal()
```

Avec quelques géométries bien choisies, on couvre déjà la majorité des besoins d'un premier cours.