

Devoir maison 1 — Importer, transformer et visualiser des données

UE INF-STAR

Oskar Laverny

30 septembre 2026

Table des matières

Informations pratiques	1
Contexte	1
Exercice 1 — Préparer le projet et explorer les données — 3 points	2
Exercice 2 — Sélectionner et transformer — 5 points	2
Exercice 3 — Résumer et comparer des groupes — 3 points	2
Exercice 4 — Visualiser et communiquer — 5 points	3
Exercice 5 — Répéter avec une boucle — 4 points	3
Présentation du rendu	3

Informations pratiques

Ce devoir est **individuel**. Il mobilise les parties 01 à 05 du cours : prise en main de R, import et exploration de données, transformations avec `dplyr`, visualisation avec `ggplot2` et boucles.

- **Données** : `data/heart.csv`.
- **Rendu attendu** : `NOM_Prenom_DM1.qmd` et le fichier `NOM_Prenom_DM1.pdf` obtenu avec Quarto.

Votre document doit pouvoir être rendu intégralement depuis une session R propre. Il doit réunir le code, les résultats utiles, les graphiques et les réponses rédigées. Utilisez uniquement des chemins relatifs : aucun chemin propre à votre ordinateur ne doit apparaître dans le code.

Contexte

Le fichier `heart.csv` contient 303 observations issues d'un jeu de données consacré à la maladie coronarienne. Chaque ligne correspond à une personne et chaque colonne décrit une caractéristique clinique. Dans ce devoir, ces données servent avant tout de support à des exercices de programmation et de visualisation ; il ne vous est pas demandé d'en tirer des conclusions médicales.

Les variables utilisées dans le devoir sont les suivantes :

- `age` : âge en années ;
- `sex` : sexe codé 0 pour « Femme » et 1 pour « Homme » ;
- `trestbps` : pression artérielle au repos, en mmHg ;

- `chol` : cholestérol sérique, en mg/dL ;
- `thalach` : fréquence cardiaque maximale atteinte ;
- `target` : diagnostic codé 0 en l'absence de maladie et de 1 à 4 lorsqu'une maladie est présente.

Exercice 1 — Préparer le projet et explorer les données — 3 points

1. Créez le dossier `NOM_Prenom_DM1` avec un sous-dossier `data`.
2. Placez `heart.csv` dans `data` et créez `NOM_Prenom_DM1.qmd` à la racine du dossier.
3. Dans le document Quarto, chargez les packages nécessaires puis importez les données avec `readr::read_csv()` et le chemin relatif `data/heart.csv`.
4. Affichez les six premières lignes, les dimensions et les noms des colonnes.
5. Examinez la structure des données avec `dplyr::glimpse()` et leur résumé avec `summary()`.
6. Comptez le nombre total de valeurs manquantes et le nombre de lignes dupliquées. Indiquez brièvement en commentaire ce que vous observez.

Exercice 2 — Sélectionner et transformer — 5 points

Construisez un nouveau tableau nommé `heart_prepare` sans modifier l'objet importé. À l'aide d'un pipe et des fonctions vues dans la partie 03 :

1. conservez uniquement les variables `age`, `sex`, `trestbps`, `chol`, `thalach` et `target` ;
2. créez une variable `sexe` contenant « Femme » lorsque `sex` vaut 0 et « Homme » lorsqu'il vaut 1 ;
3. créez une variable `maladie` contenant « Absente » lorsque `target` vaut 0 et « Présente » sinon ;
4. créez une variable `classe_age` comportant les trois catégories < 45, 45-59 et 60+ ;
5. supprimez les colonnes `sex` et `target`, devenues inutiles ;
6. trie le tableau de la personne la plus âgée à la plus jeune et affichez ses dix premières lignes ;
7. vérifiez avec `count()` les effectifs des catégories créées.

Exercice 3 — Résumer et comparer des groupes — 3 points

À partir de `heart_prepare` :

1. calculez, pour chaque modalité de `maladie` :
 - le nombre d'observations ;
 - l'âge moyen ;
 - le cholestérol moyen ;
 - la pression artérielle moyenne ;
 - la fréquence cardiaque maximale moyenne ;
2. calculez le nombre d'observations pour chaque combinaison de `classe_age` et de `maladie` ;
3. créez un tableau contenant uniquement les personnes de 60 ans ou plus dont le cholestérol est supérieur à 250, puis conservez `age`, `sexe`, `chol`, `trestbps` et `maladie` ;
4. commentez en deux ou trois phrases les principales différences descriptives observées entre les groupes. Ces comparaisons ne permettent pas, à elles seules, d'établir une relation causale ni de formuler un diagnostic médical.

Exercice 4 — Visualiser et communiquer — 5 points

Réalisez les quatre graphiques suivants avec `ggplot2` :

1. un histogramme de l'âge avec des classes de largeur 5 ans ;
2. un diagramme en barres montrant les effectifs des modalités de `maladie`, avec une couleur différente pour chaque modalité ;
3. des boxplots du cholestérol selon `maladie` ;
4. un nuage de points représentant la fréquence cardiaque maximale (`thalach`) en fonction de l'âge :
 - colorez les points selon `maladie` ;
 - créez une facette par `sexe` ;
 - ajoutez une droite de tendance linéaire sans intervalle de confiance.

Chaque graphique doit comporter un titre informatif, des axes nommés en français, une légende explicite lorsque nécessaire et un thème lisible.

Faites apparaître les quatre graphiques dans le document final, à proximité des questions correspondantes. Expliquez en deux ou trois phrases ce que montre le quatrième graphique, sans dépasser ce que permettent les données.

Exercice 5 — Répéter avec une boucle — 4 points

1. Créez un vecteur contenant les noms des variables quantitatives `age`, `trestbps`, `chol` et `thalach`.
2. Préallouez un vecteur numérique nommé destiné à recevoir leur moyenne.
3. À l'aide d'une boucle `for`, parcourez les noms des variables et calculez leur moyenne. Affichez le résultat.
4. Préallouez ensuite un vecteur de caractères de même longueur que le nombre de lignes de `heart_prepare`.
5. À l'aide d'une boucle `for` et d'une instruction `if/else`, remplissez ce vecteur avec « Élevé » lorsque `chol` est supérieur ou égal à 240 et « Autre » sinon.
6. Produisez le même résultat sans boucle avec `ifelse()`.
7. Vérifiez que les deux vecteurs sont identiques et expliquez en une ou deux phrases quelle écriture vous semble la plus naturelle pour cette classification.

Présentation du rendu

Le fichier `NOM_Prenom_DM1.qmd` doit utiliser au minimum l'en-tête suivant :

```
---
title: "Devoir maison 1"
author: "Prénom NOM"
format: typst
---
```

Le document doit contenir :

- une courte introduction ;
- une section clairement identifiée par exercice ;
- le code nécessaire dans des cellules R ;

- les résultats et graphiques utiles, placés près des commentaires correspondants ;
- des réponses rédigées en français, en dehors des cellules de code ;
- des noms d'objets explicites et un code lisible ;
- aucun appel à `setwd()` et aucun chemin absolu.

Avant le dépôt, fermez votre session R puis rendez de nouveau le document depuis le début. Vérifiez que le PDF est produit sans erreur et que tous les tableaux et graphiques demandés sont visibles.

On n'attend pas un long rapport : la priorité est donnée à un document clair, correct et reproductible. Les deux fichiers `.qmd` et `.pdf` doivent être remis.